

- ~~Examen~~
- Segundo Parcial: Inferencia Estadística
 - Maestría en Computo Estadístico.
 - Enrique Santibañez Cortés.

Ejercicio 1.

Tenemos que $X_1, \dots, X_n \sim \text{Gamma}(\alpha, \beta)$.

Recordemos que para una v.a $X \sim \text{Gamma}(\alpha, \beta)$.

$$E[X] = \frac{\alpha}{\beta} \quad \& \quad \text{Var}(X) = \frac{\alpha}{\beta^2}, \Rightarrow E[X^2] = \frac{\alpha}{\beta^2} + \left(\frac{\alpha}{\beta}\right)^2$$

$$\begin{aligned} E[X^2] &= \cancel{\frac{\alpha}{\beta^2} + \frac{\alpha^2}{\beta^2}} \\ &= \frac{\alpha}{\beta^2} + \frac{\alpha^2}{\beta^2} \\ &= \frac{\alpha(1+\alpha)}{\beta^2} \end{aligned}$$

Con lo anterior, tenemos que por el método de momento:

$$E[X] = \frac{\alpha}{\beta} = \frac{1}{n} \sum_{i=1}^n x_i \quad \& \quad E[X^2] = \frac{\alpha(1+\alpha)}{\beta^2} = \frac{1}{n} \sum_{i=1}^n x_i^2$$

Despejando y resolviendo el sistema \uparrow tenemos que:

$$\alpha = \frac{\beta}{n} \sum_{i=1}^n x_i, \text{ sustituyendo en (2), } \Rightarrow \frac{\beta \bar{x} (1 + \beta \bar{x})}{\beta^2} = \frac{1}{n} \sum_{i=1}^n x_i^2$$

$$\Rightarrow \bar{x} (1 + \beta \bar{x}) = \frac{\beta}{n} \sum_{i=1}^n x_i^2$$

$$\bar{x} + \beta (\bar{x})^2 = \frac{\beta}{n} \sum_{i=1}^n x_i^2$$

$$\beta (\bar{x})^2 - \frac{\beta}{n} \sum_{i=1}^n x_i^2 = -\bar{x}$$

$$\beta \left(\bar{x}^2 - \frac{1}{n} \sum_{i=1}^n x_i^2 \right) = -\bar{x}$$

Para simplificar la notación $\bar{x} = \frac{1}{n} \sum x_i$

\Rightarrow Un estimador por el método de momentos para β es:

$$\begin{aligned}\hat{\beta}^n &= \frac{-\bar{X}}{\bar{X}^2 - \frac{1}{n} \sum_{i=1}^n x_i^2} = \frac{-\bar{X}}{-\frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2} \\ &= \frac{\bar{X}}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2} = \frac{\bar{X}}{S_n^2}\end{aligned}$$

Y un estimador por el método de momentos para α es

$$\begin{aligned}\hat{\alpha}^n &= \hat{\beta}^n \bar{X} = \frac{\bar{X}^2}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2} \\ &= \frac{\bar{X}^2}{S_n^2}\end{aligned}$$

Es decir, los estimadores de β y α están en función de la media muestral y la varianza muestral.

Ejercicio 2.

Enrique Santibáñez Cortés

Para validar que $f(x)$ es una función de densidad, observemos que $f(x) > 0$ y que la función $f(x)$ integra 1 en el intervalo que está definida (α, ∞) .

- Es trivial ver que $f(x) > 0$, (por como está construida),
- Ahora validemos que integra 1:

$$\begin{aligned}
 \int_{\alpha}^{\infty} \frac{1}{\beta} e^{\frac{-x+\alpha}{\beta}} dx &= \frac{1}{\beta} \int_{\alpha}^{\infty} e^{\frac{-x+\alpha}{\beta}} dx \\
 &= \frac{1}{\beta} \int e^m (-\beta) dm \quad \left. \begin{array}{l} m = \frac{-x+\alpha}{\beta} \\ dm = -\frac{1}{\beta} dx \end{array} \right\} \\
 &= -e^{\frac{-x+\alpha}{\beta}} \bigg|_{x=\alpha}^{\lim_{x \rightarrow \infty}} \\
 &= -\lim_{x \rightarrow \infty} e^{\frac{-x+\alpha}{\beta}} + e^{\frac{-\alpha+\alpha}{\beta}} \\
 &= 0 + e^{\frac{0}{\beta}} = 1
 \end{aligned}$$

∴ $f(x)$ del ejercicio si es una función de densidad.

Ahora encontramos la verosimilitud:

$$\begin{aligned}
 L(\theta) &= L(\alpha, \beta; x_1, x_2, \dots, x_n) = \prod_{i=1}^n \frac{1}{\beta} e^{\frac{-x_i+\alpha}{\beta}} = \frac{1}{\beta^n} e^{\frac{-\sum x_i}{\beta}} \cdot e^{\frac{n\alpha}{\beta}} \\
 \Rightarrow \log(L(\theta)) &= -n \log(\beta) + \frac{n\alpha}{\beta} - \frac{\sum x_i}{\beta}
 \end{aligned}$$

Ahora encontremos la verosimilitud de (θ) .

$$L(\theta) = L(\alpha, \beta; x_1, \dots, x_n) = \prod_{i=1}^n \frac{e^{-x_i + \alpha}}{\beta} 1_{[\alpha, \infty)}(x_i)$$

$$= \frac{1}{\beta^n} e^{-\sum x_i} \cdot e^{n\alpha} 1_{(\alpha, \infty)}(x_{(n)}) \cdot 1_{(\alpha, \infty)}(x_{(1)})$$

donde $x_{(n)}$, $x_{(1)}$ son los estadísticos de orden. Ahora calculemos el $\log(L(\theta))$

$$\log(L(\theta)) = -n \log(\beta) + \frac{n\alpha}{\beta} - \frac{\sum x_i}{\beta} \quad \begin{matrix} \alpha < x_{(1)} \dots < \infty \\ -\infty < \alpha < \infty \\ \alpha < \beta \end{matrix}$$

Para algún β fijo, observemos que no es factible derivar en α ya que el término no estaría en función de α .

Pero si $L(\theta)$ se hace ~~1/\beta~~ antes del valor ~~de α~~ ~~que~~ y sabiendo que $\alpha < x_{(1)}$.

$L(\theta)$ se maximiza cuando $\alpha \leq x_{(1)}$. por lo que el estimador de máxima verosimilitud para α es

$\hat{\alpha} = x_{(1)}$, $x_{(1)}$ es el ^{primer} estadístico de orden.

Para encontrar un estimador de β derivemos la $\log(L(\theta))$

$$\frac{d}{d\beta} \log(L(\theta)) = \frac{-n}{\beta} - \frac{n x_{(1)}}{\beta^2} + \frac{\sum x_i}{\beta^2},$$

Ahora igualamos a cero para maximizar.

$$\frac{-n}{\beta} - \frac{n X_{(1)}}{\beta^2} + \frac{\sum X_i}{\beta^2} = 0$$

Multiplicamos
por β^2

$$- \beta n - n X_{(1)} + \sum_{i=1}^n X_i = 0$$

$$- \beta n = n X_{(1)} - \sum_{i=1}^n X_i$$

Esto implica que el estimador de máxima verosimilitud para β es:

$$\hat{\beta}^n = -X_{(1)} + \bar{X}$$



Ejercicio 5.

Enrique Santibañez Cortés

El valor que minimiza ~~es~~ $E[(Y-g(x))^2]$ es

$$g(x) = E[Y|X].$$

Para demostrar que minimiza a ~~la función~~ $E[(Y-g(x))^2]$
veamos que: (por propiedades de la esperanza:)

$$\begin{aligned} E[(Y-g(x))^2] &= E[(Y-g(x) + E[Y|X] - E[Y|X])^2] && \text{(sumamos un cero)} \\ &= E[(Y - E[Y|X] + (E[Y|X] - g(x)))^2] && \text{(reagrupamos)} \\ &= E[(Y - E[Y|X])^2 + 2(Y - E[Y|X])(E[Y|X] - g(x)) \\ &\quad + (E[Y|X] - g(x))^2] \\ &= E[(Y - E[Y|X])^2 + 2E[(Y - E[Y|X])(E[Y|X] - g(x))] \\ &\quad + E[(E[Y|X] - g(x))^2]], \end{aligned}$$

Ahora ocupando ~~ese~~ la siguiente propiedad de la esperanza:

$$E[E[Y|X]] = E[Y].$$

Para ser más entendible la demostración trabajemos el segundo término de la igualdad por separado.

Es decir,

$$\begin{aligned} \# 2 \ E[(Y - E[Y|X])(E[Y|X] - g(x))] &= 2 E[(Y - E[Y|X]) E[E[Y|X] - g(x)]] \\ &= 2 (E[Y] - E[E[Y|X]]) (E[E[Y|X]] - E[g(x)]) \\ &= 2 (E[Y] - E[Y]) (E[E[Y|X]] - E[g(x)]) \\ &= 0 \end{aligned}$$

Regresando a $\#1$,

$$E[(Y - g(x))^2] = E[(Y - E[Y|X])^2] + E[(E[Y|X] - g(x))^2].$$

Ahora observemos que el argumento de todas las esperanzas anteriores están elevadas al cuadrado, esto implica que todas sean positivas o iguales a cero (se puede demostrar sencillamente, pero se asume que es trivial).

Entonces como son positivos tenemos que:

$$E[(Y - g(x))^2] = E[(Y - E[Y|X])^2] + E[(E[Y|X] - g(x))^2] \geq E[(Y - E[Y|X])^2].$$

Es decir, lo anterior se interpreta a que $E[(Y - g(x))^2]$ tiene un mínimo (una cota inferior), y el mínimo se alcanza cuando $g(x) = E[Y|X]$. Por lo tanto, queda demostrado

que $g(x) = E[Y|X]$ minimiza $E[(Y - g(x))^2]$

Ejercicio 6.

Enrique Santibañez Cortes

Usando el teorema de Box-Müller.

Justificación del programa:

Si $U_1 \sim \text{Unif}(0,1)$ y $U_2 \sim \text{Unif}(0,1)$ independientes.

$$\Rightarrow X = \sqrt{-2 \ln(U_1)} \cos(2\pi U_2) \sim N(0,1)$$

$$Y = \sqrt{-2 \ln(U_1)} \sin(2\pi U_2) \sim N(0,1).$$

Para demostrar lo anterior, veamos que ~~se~~ podemos probar que $- \beta \ln(U_1) \sim \text{Exp}(\beta)$ y $2\pi U_2 \sim \text{Unif}(0, 2\pi)$. Para mostrarlo por el método de transformación de variables: Sea

$$M = -\beta \ln(U_1) \text{ y } L = 2\pi U_2$$

$$\Rightarrow \text{transformación inversa: } U_1 = \exp\left(\frac{-m}{\beta}\right) \text{ y } U_2 = \frac{L}{2\pi}$$

Observemos que

$$X = \{(u_1, u_2) \mid u_1 \in (0,1), u_2 \in (0,1)\} \Rightarrow Y = \{(m, L) \mid m \in \mathbb{R}^+, L \in (0, 2\pi)\}$$

Entonces el Jacobiano es:

$$|J| = \begin{vmatrix} -\frac{1}{\beta} \exp\left(\frac{-m}{\beta}\right) & 0 \\ 0 & \frac{1}{2\pi} \end{vmatrix} = \frac{\beta}{2\pi} \exp\left(\frac{-m}{\beta}\right)$$

Entonces como U_1 y U_2 eran independientes
 \Rightarrow

$$f_{M,L}(m,l) = \frac{1}{\beta} \exp\left(-\frac{m}{\beta}\right) \frac{1}{2\pi}, \quad 0 < m < \infty, \quad 0 < l < 2\pi$$

Calculando las marginales de M y L , tenemos que:

$$f_M(m) = \int_0^{2\pi} \frac{1}{\beta} \exp\left(-\frac{m}{\beta}\right) \frac{1}{2\pi} dl = \frac{1}{\beta} \exp\left(-\frac{m}{\beta}\right), \quad 0 < m < \infty$$

$$f_L(l) = \int_0^{\infty} \frac{1}{\beta} \exp\left(-\frac{m}{\beta}\right) \frac{1}{2\pi} dm = \frac{1}{2\pi} \quad 0 < l < 2\pi$$

Con lo anterior podemos decir que efectivamente,

$$-\beta \ln(U_1) \sim \text{Exp}(\beta) \quad \& \quad \sin(2\pi U_2) \sim \text{Unif}(0, 2\pi)$$

independientes.

Ahora demostramos de X y $Y \sim N(0,1)$, para ello definimos las siguientes transformaciones:

$$\begin{aligned} M &= X^2 + Y^2 & L &= \tan^{-1}\left(\frac{Y}{X}\right) \end{aligned}$$

\Rightarrow las inversas:

$$X = \sqrt{-2 \ln(U_1)} \cos(2\pi U_2) = \sqrt{M} \cos(L)$$

$$Y = \sqrt{-2 \ln(U_1)} \sin(2\pi U_2) = \sqrt{M} \sin(L)$$

Observemos que son funciones uno a uno, por lo que el Jacobiano es:

$$|J| = \begin{vmatrix} \frac{\cos(t)}{2\sqrt{t}} & -\sqrt{t} \sin(t) \\ \frac{\sin(t)}{2\sqrt{t}} & \sqrt{t} \cos(t) \end{vmatrix} = \frac{\sqrt{t}}{2\sqrt{t}} \cos^2(t) + \frac{\sqrt{t}}{2\sqrt{t}} \sin^2(t) = \frac{1}{2}$$

Por lo tanto la densidad conjunta de X y Y es:

$$f_{X,Y}(x,y) = \exp\left(-\frac{x^2+y^2}{2}\right) \frac{1}{2\pi} \quad \begin{matrix} -\infty < x < \infty \\ -\infty < y < \infty \end{matrix}$$

Entonces las marginales de X y Y son:

$$\begin{aligned} f_X(x) &= \int_{-\infty}^{\infty} \exp\left(-\frac{x^2+y^2}{2}\right) \frac{1}{2\pi} dy \\ &= \frac{\exp\left(-\frac{x^2}{2}\right)}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \frac{\exp\left(-\frac{y^2}{2}\right)}{\sqrt{2\pi}} dy \quad \text{Integral 1} \\ &= \frac{\exp\left(-\frac{x^2}{2}\right)}{\sqrt{2\pi}}, \quad -\infty < x < \infty \end{aligned}$$

$$\begin{aligned} f_Y(y) &= \int_{-\infty}^{\infty} \exp\left(-\frac{x^2+y^2}{2}\right) \frac{1}{2\pi} dx = \dots = \\ &= \frac{\exp\left(-\frac{y^2}{2}\right)}{\sqrt{2\pi}}, \quad -\infty < y < \infty \end{aligned}$$

Por lo, tanto X y Y son $N(0,1)$. ~~if~~

Es decir, hemos demostrado que a partir de v.a. uniforme podemos generar muestras normales estandar,

Una vez generadas las muestras normales es sencillo generar muestras normales con esperanza y varianza solicitadas.

Si X_1 es una observación de una Normal estandar entonces

$h_1 = \mu + \sigma X_1$, será una observación de una $N(\mu, \sigma^2)$

