

## Problem Honors

1.- Sea  $X_1, \dots, X_n$  una muestra aleatoria de una v.a. Bernoulli con  $P(X=1)=p$ , donde  $p \in (0,1)$  es desconocido. Sea  $\hat{\theta}$  el estimador de máxima verosimilitud de  $\theta = p(1-p)$ .

a) Muestre que  $\hat{\theta}$  es asintóticamente normal cuando  $p \neq \frac{1}{2}$ .  
Respuesta.

Teorema 1. (Diapositivas, 72p)

Bajo apropiadas condiciones de regularidad, el mle  $\hat{\theta}$

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d} N(0, I_1(\theta)^{-1}).$$

Teorema 2. (Casella, 499p).

$$\text{Var}(h(\hat{\theta}) | \theta) \approx \frac{[h'(\theta)]^2}{I_n(\theta)} \approx \frac{[n'(\theta)]^2 |_{\theta=\theta^0}}{-\frac{\partial^2}{\partial \theta^2} \log L(\theta | x) |_{\theta=\theta^0}}.$$

Por las clases sabemos que el estimador de MLE para el caso Bernoulli de  $p$  es  $\hat{p} = \bar{X}$ . Ahora, esto implica que el estimador de la varianza para el caso Bernoulli es

$$\hat{\theta} = \hat{p}(1-\hat{p}) = \bar{X}(1-\bar{X}).$$

Una manera de abordar este problema sería calcular la varianza de  $\bar{X}(1-\bar{X})$  pero eso complica la respuesta.

Por lo que utilizaremos el teorema 2 para encontrarla.

$$\begin{aligned}\widehat{\text{Var}}(\hat{\theta}) &= \widehat{\text{Var}}(\hat{p}(1-\hat{p})) = \frac{\left\{ \frac{\partial}{\partial p} (p(1-p)) \right\}^2 \Big|_{p=\hat{p}}}{-\frac{\partial^2}{\partial p^2} \log L(p|x) \Big|_{p=\hat{p}}} \\ &= \frac{(1-2\hat{p})^2 \Big|_{p=\hat{p}}}{\frac{n}{\hat{p}(1-\hat{p})} \Big|_{p=\hat{p}}} \\ &= \frac{\hat{p}(1-\hat{p})(1-2\hat{p})^2}{n}\end{aligned}$$

Observemos que si  $p = \frac{1}{2} \Rightarrow \widehat{\text{Var}}(\hat{\theta}) = 0$ , por lo que se estaría sobreestimando. Por lo que consideremos el caso cuando  $p \neq \frac{1}{2}$ . Por lo tanto, ocupando el teorema 1 podemos concluir que

$$\sqrt{n}(\hat{\theta} - p(1-p)) \xrightarrow{d} N(0, (1-p)p(1-2p)^2) \Leftrightarrow \sqrt{n}(\bar{x}(1-\bar{x}) - p(1-p)) \xrightarrow{d} N(0, \frac{p(1-p)}{(1-2p)^2})$$

Es decir,  $\hat{\theta}$  es asintóticamente normal (para  $p \neq \frac{1}{2}$ ).

b) Cuando  $p = \frac{1}{2}$ , usando una normalización adecuada, deriva una distribución asintótica no degenerada de  $\hat{\theta}$ .

Respuesta.

Ocuparemos el teorema S.S. 26 del Casella.

Teorema S.S. 26

Sea  $Y_n$  una m.a. que satisface  $\sqrt{n}(Y_n - \theta) \rightarrow N(0, \sigma^2)$  en distribución. Para alguna función  $g$  y un valor específico de  $\theta$ , supongase que  $g'(\theta) = 0$  y  $g''(\theta)$  existe y no es 0. Entonces

$$n[g(Y_n) - g(\theta)] \xrightarrow{d} \sigma^2 \frac{g''(\theta)}{2} \chi_1^2.$$

En el inciso anterior y probamos que se satisface  $\sqrt{n}(Y_n - \theta) \xrightarrow{d} N(0, \sigma^2)$ .  $\star$ ,  $Y_n = \bar{X}$ .

$$\text{Sea } g(\theta) = p(1-p) \Rightarrow g'(\theta) = 1-2p$$

$$\text{Pero como } p = \frac{1}{2} \Rightarrow$$

$$g(\theta) = \frac{1}{4} \quad \& \quad g'(\theta) = 0.$$

$$\text{Y además } g''(\theta) = -2.$$

Por lo tanto podemos concluir que

$$n[Y_n(1-Y_n) - \frac{1}{4}] \xrightarrow{d} -\frac{1}{4} \chi_1^2$$

Es decir, encontramos una distribución asintótica no degenerada.

Nota:  $\star$  no es la demostración es directa considerando que  $\hat{\theta}_{MLE} = \bar{X} \Rightarrow \sqrt{n}(Y_n - p) \xrightarrow{d} N(0, p(1-p))$ , es decir, usar la media.



3. Para el caso presentado en el ejemplo anterior sin usar el teorema de Wilks, justifique que la distribución asintótica de  $-2 \log \lambda(x)$  es  $\chi^2$ .

Respuesta:

Enunciemos los siguientes teoremas:

Teorema 1

Sea  $\{X_n\}$  convergente a  $X$  en distribución, y sea  $\{Y_n\}$  convergente en probabilidad a cero. Entonces  $\{X_n Y_n\}$  converge en probabilidad a cero.

Teorema 2,

Sea  $\hat{\theta}^{(n)}$  el estimador de MLE de  $\theta$ , si este existe y es único (si no,  $\hat{\theta}^n$  se define algún arbitrario).

Bajo ciertas condiciones, el límite distribuciónal de  $\sqrt{n}(\hat{\theta}^n - \theta)$  es  $N(0, J^{-1})$ , y  $\hat{\theta}^n$  converge en probabilidad a  $\theta$ .

Teorema 3.

Sea  $\{\theta^{(n)}\}$  convergente en probabilidad a  $\theta$ . Bajo ciertas condiciones para  $i, j = 1, 2, \dots, r$ , de la secuencia

$\left\{ -n^{-1} \frac{\partial^2 \ln(\theta^{(n)})}{\partial \theta_i \partial \theta_j} \right\}$  converge en probabilidad a  $J_{ij}$ ,

Teorema 4,

$$-2 \log \lambda(x) = \sqrt{n} (\hat{\theta}^n - \theta)^T \left[ -n^{-1} \frac{\partial^2 \ln(\theta^{(n)})}{\partial \theta_i \partial \theta_j} \right] \sqrt{n} (\hat{\theta}^n - \theta).$$

Ocupando el teorema 4 tenemos que

$$-2 \log \lambda(x) = \sqrt{n}(\hat{\theta}^n - \hat{\theta})^T \left[ -n^{-1} \frac{\partial^2 \ln(\theta^*)}{\partial \theta_i \partial \theta_j} \right] \sqrt{n}(\hat{\theta}^n - \hat{\theta}).$$

Y ocupando el teorema 2, tenemos que  $\{\theta^*\}$  converge en probabilidad a  $\theta^0$ . Y ocupando el teorema 3, tenemos que para cada  $i, j = 1, \dots, r$  de los elementos de la matriz  $\left[ -n^{-1} \frac{\partial^2 \ln(\theta^*)}{\partial \theta_i \partial \theta_j} \right]$  converge a  $J_{ij}$ . Por lo que, tenemos que

$$-2 \log \lambda(x) = \sqrt{n}(\hat{\theta}^n - \hat{\theta})^T J \sqrt{n}(\hat{\theta}^n - \hat{\theta}).$$

Y por último ocupando nuevamente el teorema 2, podemos ver que  $\sqrt{n}(\hat{\theta}^n - \hat{\theta}) \rightsquigarrow N(0, J^{-1})$  y por las propiedades de la distribución Normal

$\Rightarrow$

$$-2 \log \lambda(x) = \sqrt{n}(\hat{\theta}^n - \hat{\theta})^T J \sqrt{n}(\hat{\theta}^n - \hat{\theta}) \sim \chi^2_r$$
